数据库系统

查询处理（1）

陈世敏

（中科院计算所）

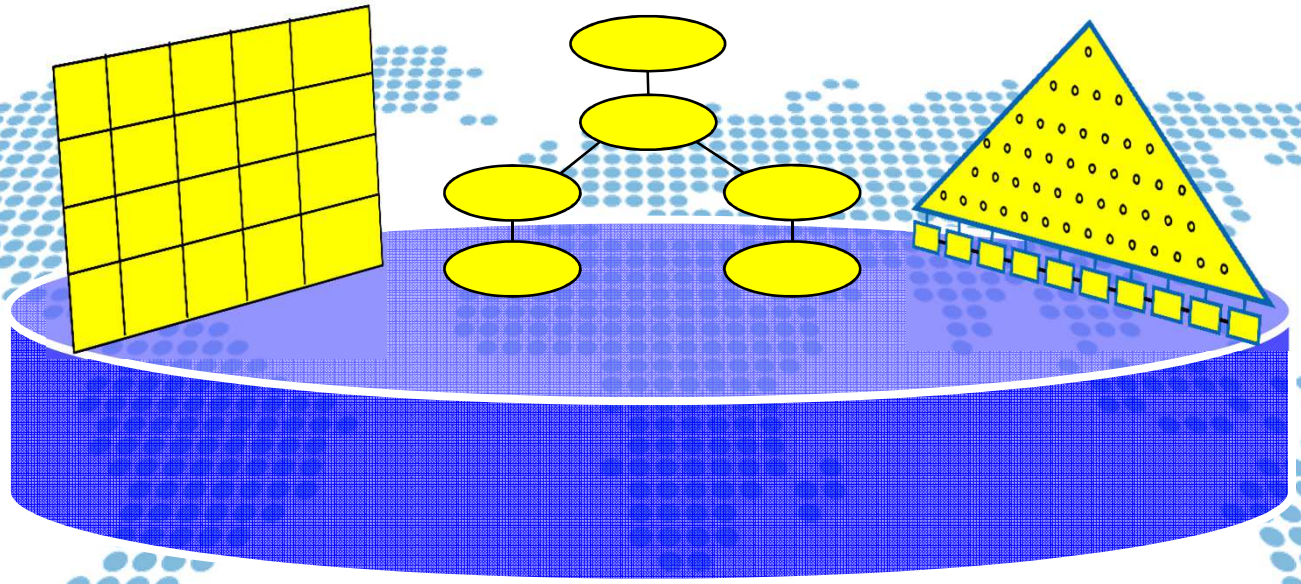

Outline

- 查询处理概述
- 排序和外排序

Outline

- 查询处理概述
  - 系统目录（System Catalog）
  - 查询执行方式
  - 关系操作实现的常见方式
- 排序和外排序

系统目录（System Catalog）

- 又称为目录表（Catalog Table），数据字典（Data Dictionary），或目录（Catalog）
- 存储数据的元信息
  - 表的信息
  - 索引的信息
  - 视图的信息
  - 其它：grant，check constraints, trigger等

对于每个Table

- 表名
- 表的存储方式
- 每个属性名和类型
- 每个索引名
- 表上的完整性约束
- 统计信息
  - 记录数（Cardinality）
  - 表大小：页数
  - 属性值的分布特征：可能包括属性取值的大致个数，统计直方图

对于每个索引

- 索引名称
- 索引结构类型
- 索引key的组成属性

- 统计信息
  - key的个数
  - 索引大小：页数
  - 树结构索引高度
  - 索引范围：最小和最大的键值

对于每个视图

- 视图的名称
- 视图的定义

目录的存储

- 系统目录也是存储在Relational Table中的
- 例如：

```
Attribute_catalog(
            attr_name string,
            rel_name string,
            type enum)
```

Outline

- 查询处理概述
  - 系统目录（System Catalog）
  - 查询执行方式
  - 关系操作实现的常见方式
- 排序和外排序

查询计划（Query Plan）

- Query optimizer产生
- Execution engine按照query plan执行

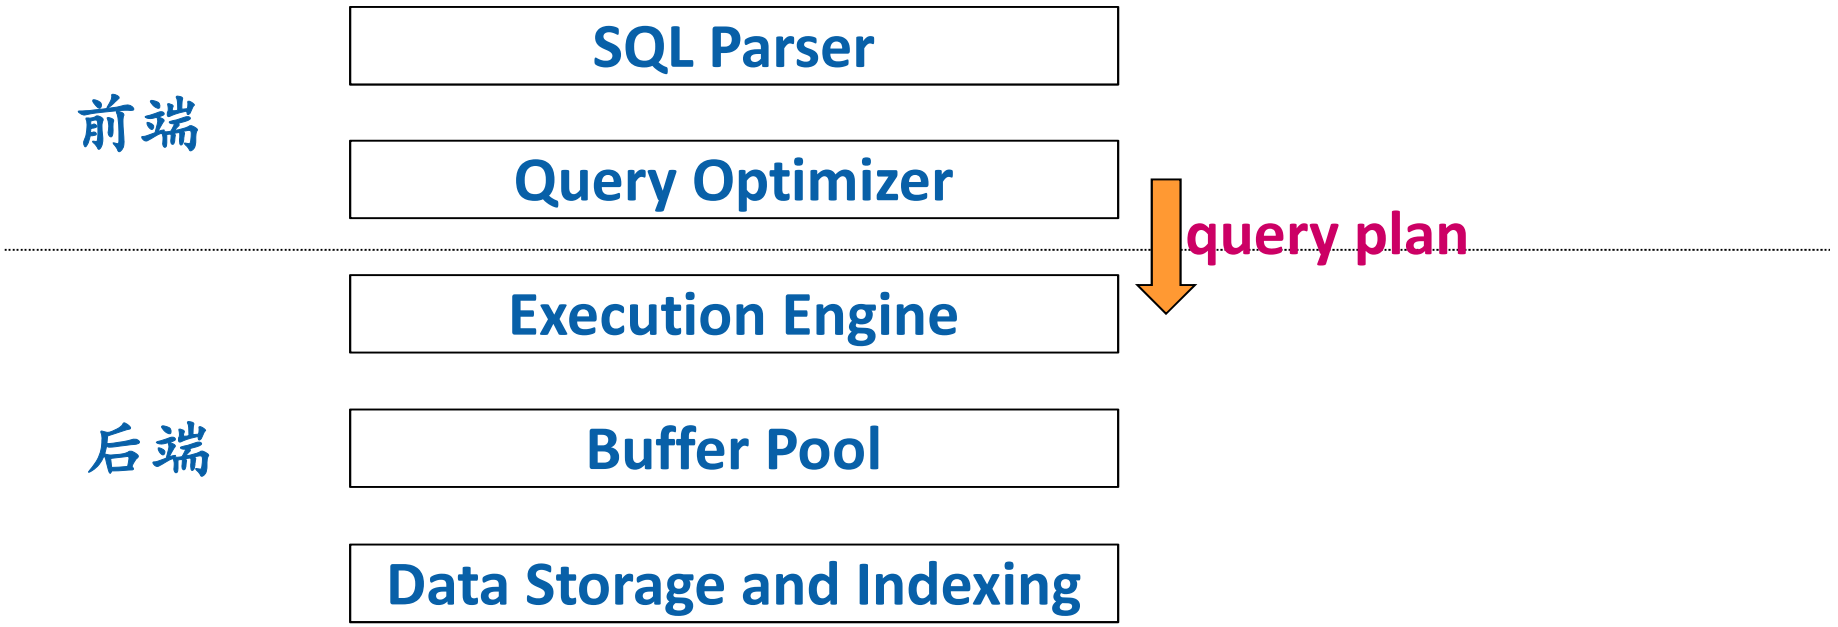

Operator Tree

- Query plan 最终将表现为一棵Operator Tree

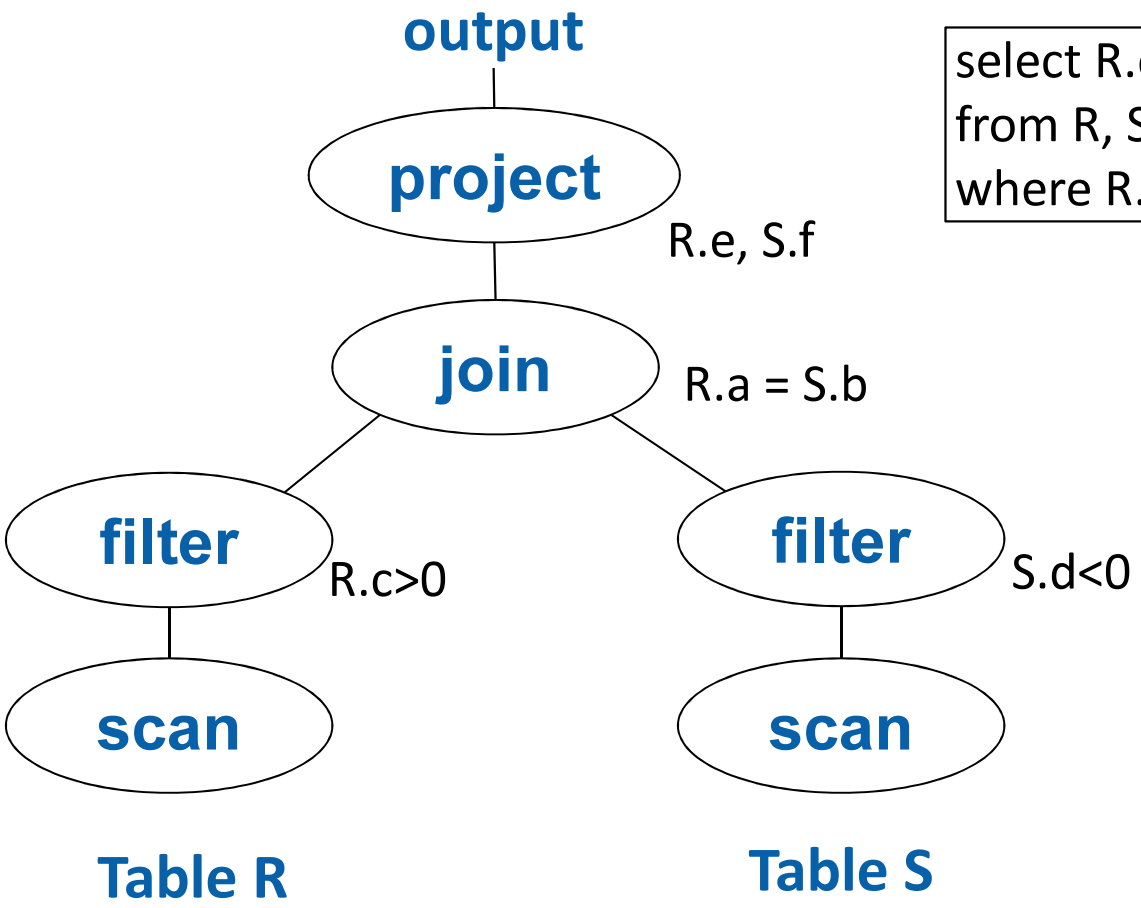


```
select R.e, S.f
from R, S
where R.a = S.b and R.c > 0 and S.d < 0;
```

Operator Tree

- Query plan 最终将表现为一棵Operator Tree
  - 每个节点代表一个运算
  - 运算的输入来自孩子节点
  - 运算的输出送往父亲节点
- 实现方法
  - 完整执行每个Operator
  - 迭代求解
  - 多线程流水线求解

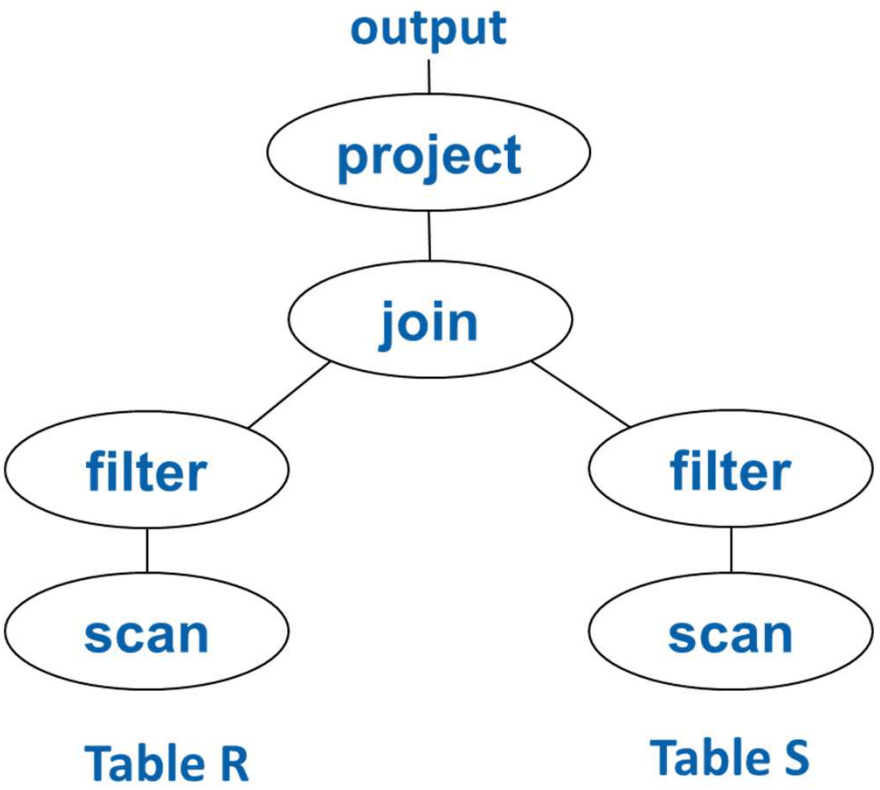

方法1：完整执行每个Operator

- Scan table R + filter
  - 完成整个操作
  - 生成中间结果表A
- Scan table S + filter
  - 完成整个操作
  - 生成中间结果表B
- Join A和B
  - 完成整个Join
  - 生成中间结果表C
- 最后在表C上计算投影
  - 得到最终结果表

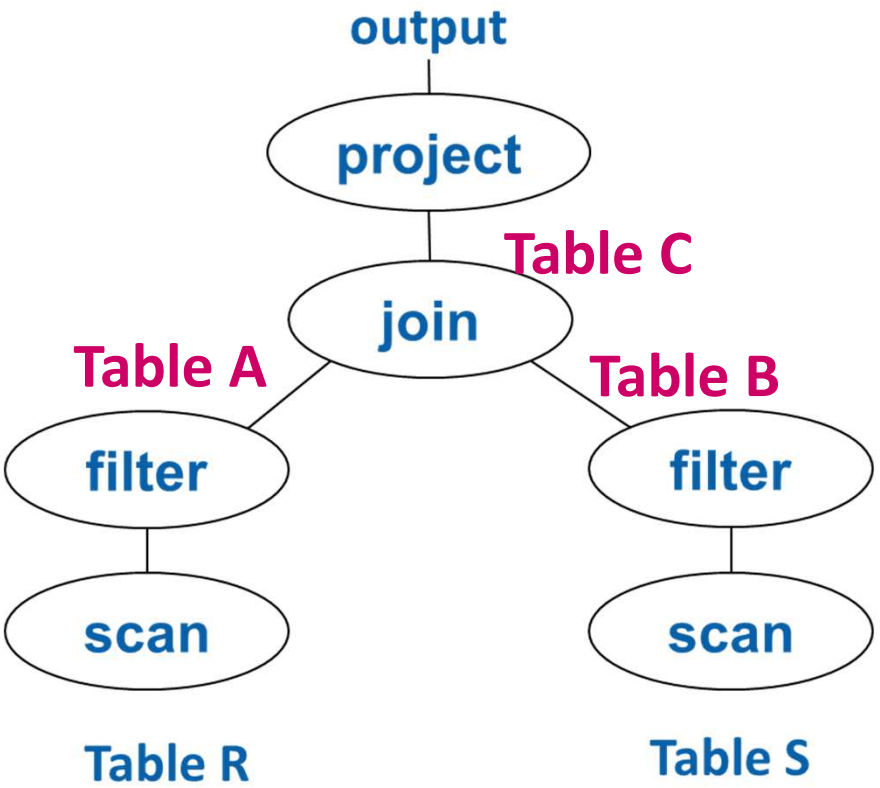

方法1的问题？

- 中间结果表的代价
  - 如果不能放入内存，那么就会有读写的I/O
  - 如果可以放入内存，但是不能放入CPU Cache，就会产生大量的Cache miss

- 我们希望减少中间结果的大小，降低中间结果的代价

方法2：迭代求解

- 每个Operator设计成为具有统一的函数接口
  - Open( )：初始化，分配资源，建立数据结构等
    - 进一步调用子Operator的open( )
  - GetNext( )：获得下一条Operator的处理结果
    - 调用子Operator的GetNext( )，在此基础上，进行本Operator所设定的关系运算，得到一条结果
  - Close( )：结束，释放资源
    - 调用子Operator的close( )

方法2：迭代求解

- 执行方式是Pull方式
- 建立了Operator tree之后
- 调用根的Open()初始化
- 循环调用根的GetNext( )
  - 父结点将调用子结点的GetNext( )
  - 生成一条条的结果
- 最后，Close( )

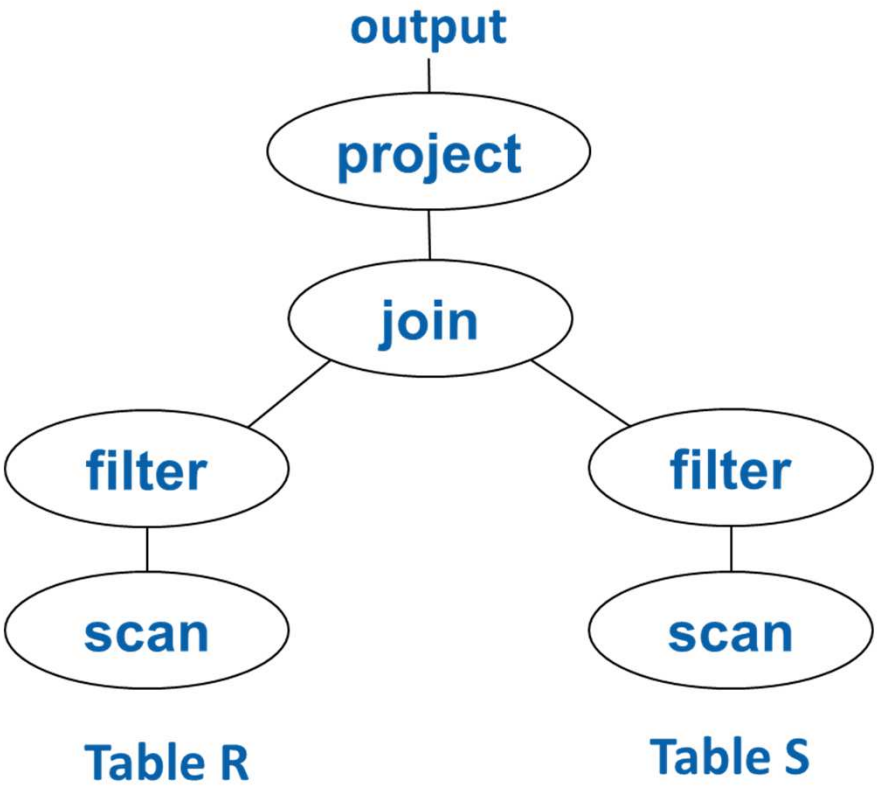

方法3：多线程流水线

- 把Operator tree分到多个线程中
  - 例如，图中把每组filter+scan在一个线程求解，一个线程求解join，一个线程求解project
- 线程之间通信传递中间结果
- 一个线程等待孩子结点的结果来到后，进行计算，产生结果，发送给父亲结点
- 这是一种push方式

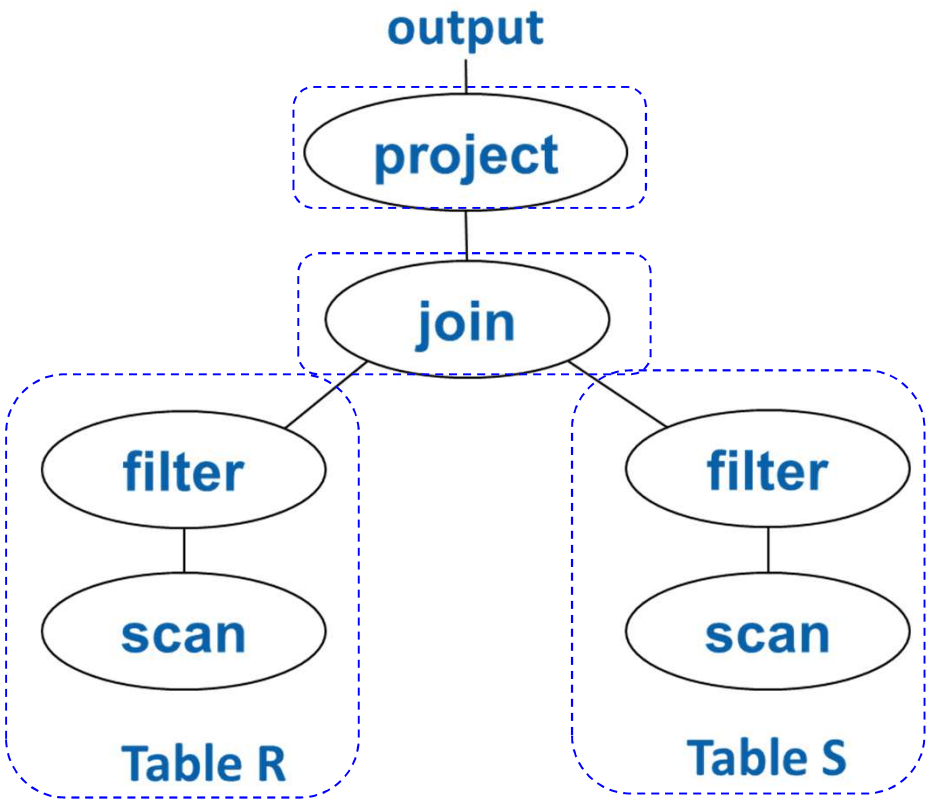

Outline

- 查询处理概述
  - 系统目录（System Catalog）
  - 查询执行方式
  - 关系操作实现的常见方式
- 排序和外排序

常用方式

- 哈希
  - 可以找到相同的属性的记录
- 排序
  - 如果记录有序，那么很多操作就可以容易实现
  - 例如去重
- 索引
  - 可以快速地查询
  - 树结构索引提供了顺序

Outline

- 查询处理概述
- 排序和外排序
  - 排序的应用场景
  - 内存排序回顾
  - 外存排序
  - 使用B^+-Tree获得排序数据

什么时候需要排序？

- Order by子句
  - 当SQL SELECT语句中使用了Order by子句
  - 用户明确要求按照给定的顺序产生查询结果
  - 那么，就需要进行排序
- B^+-tree的bulkloading
  - 在已知的数据上新建索引
  - 先按照索引键对数据进行排序，然后从叶子到根，一层层地建立B^+-Tree
- 使用排序来实现算法
  - 例如：去重distinct, 连接join, 分组group by

排序的迭代接口

- Open
  - 排序操作通常需要做大量的准备工作
  - 需要扫描全部的输入数据，调用子结点的GetNext
  - 产生中间数据结构
- GetNext
  - 生成下一条有序的结果记录
- Close
  - 释放资源

Outline

- 查询处理概述
- 排序和外排序
  - 排序的应用场景
  - 内存排序回顾
  - 外存排序
  - 使用B$^+$-Tree获得排序数据

有哪些排序算法？

- $O(N^2)$
  - 冒泡排序，选择排序，插入排序等
- O(NlogN)
  - 快速排序，归并排序，堆排序
- O(N)
  - 基数排序

快速排序？

```
quicksort(A[], lo, hi)
    if lo < hi then
        choose pivot;
        p = partition(A, lo, hi, pivot);
        quicksort(A, lo, p – 1);
        quicksort(A, p + 1, hi);
```

归并排序

- 基本操作：归并两个有序的序列
  - 怎么实现？
- 开始，所有的单个元素都是长度为1的有序序列
- 归并长度为1的有序序列➔长度为2的有序序列
- 归并长度为2的有序序列➔长度为4的有序序列
- …
- 最终得到整个有序序列

堆排序

- 这里的堆（Heap）是指二叉树，满足
  - left>=parent
  - right>=parent

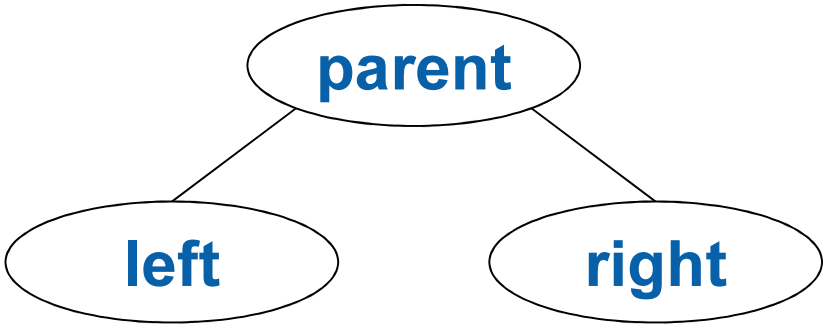

- 建立堆之后，可以从堆顶取出最小的元素
- 更新堆的代价等于树的高度O(logN)
- 这个堆与malloc/free heap不是一个概念

Outline

- 查询处理概述
- 排序和外排序
  - 排序的应用场景
  - 内存排序回顾
  - 外存排序
  - 使用B$^+$-Tree获得排序数据

外存排序

- 输入表R，大于可用内存大小M
- 步骤
  - Run Generation，生成有序的数据段
  - Merge Runs，归并数据段

Run Generation

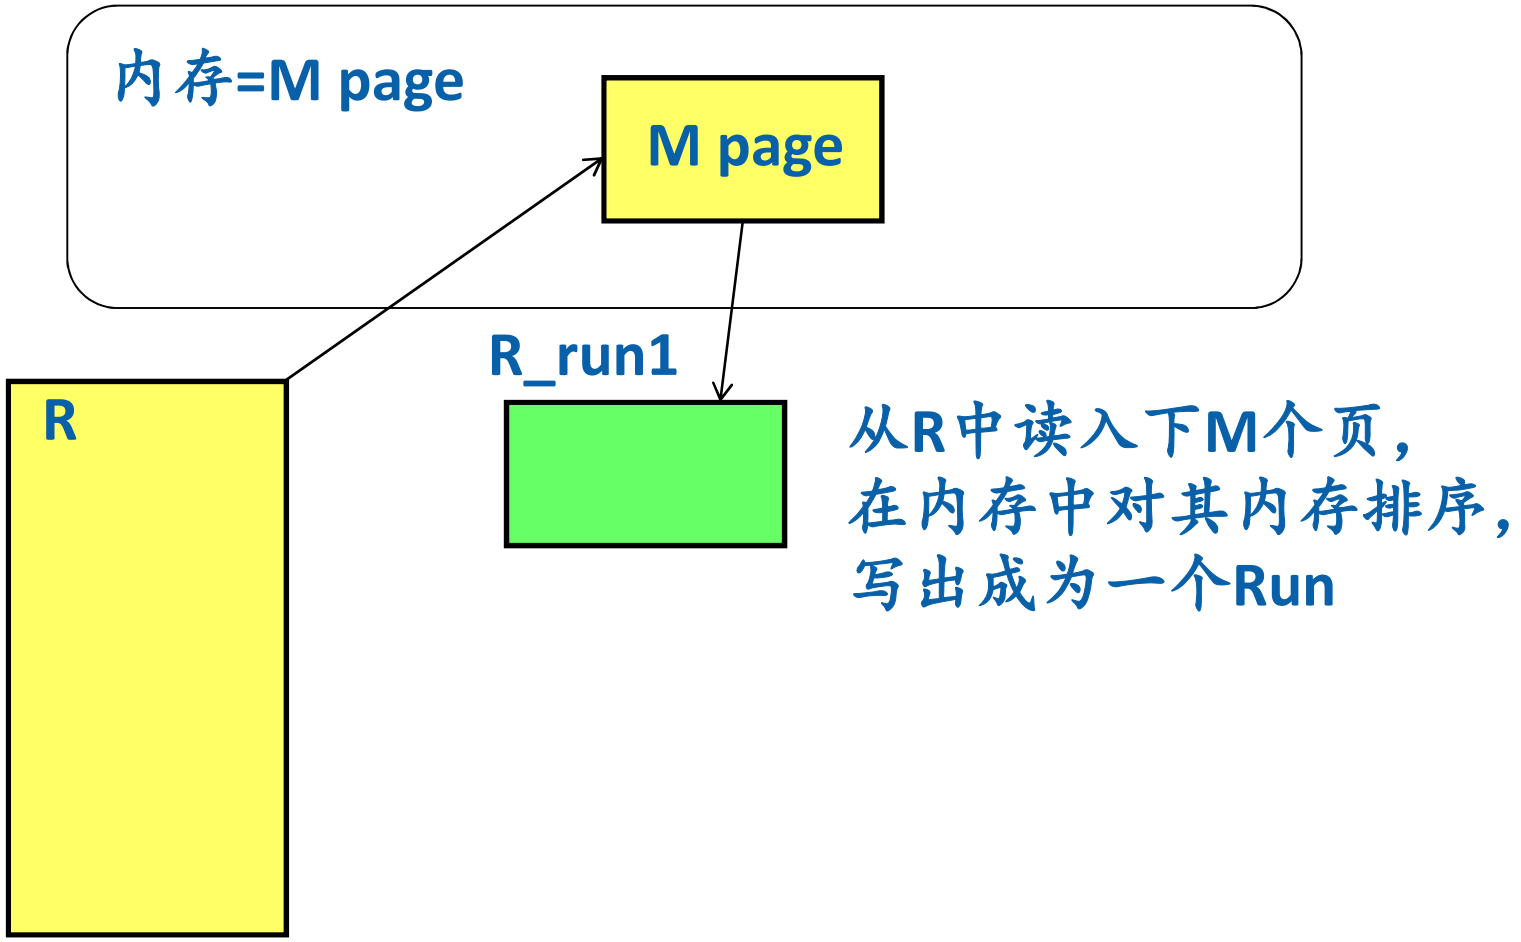

Run Generation

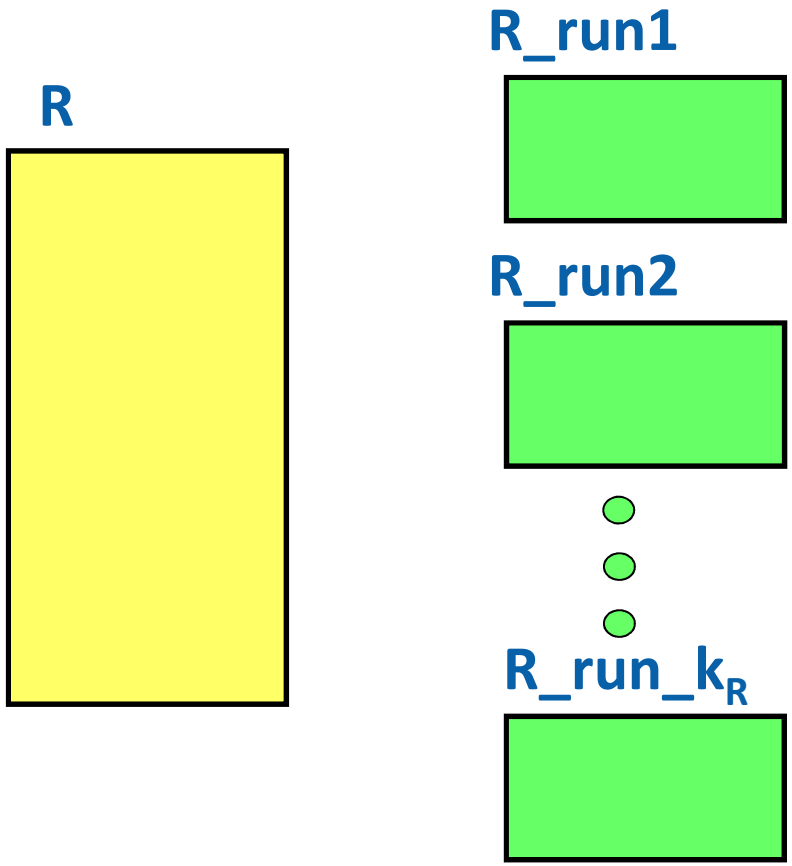

$k_R = |R|/M$

Merge

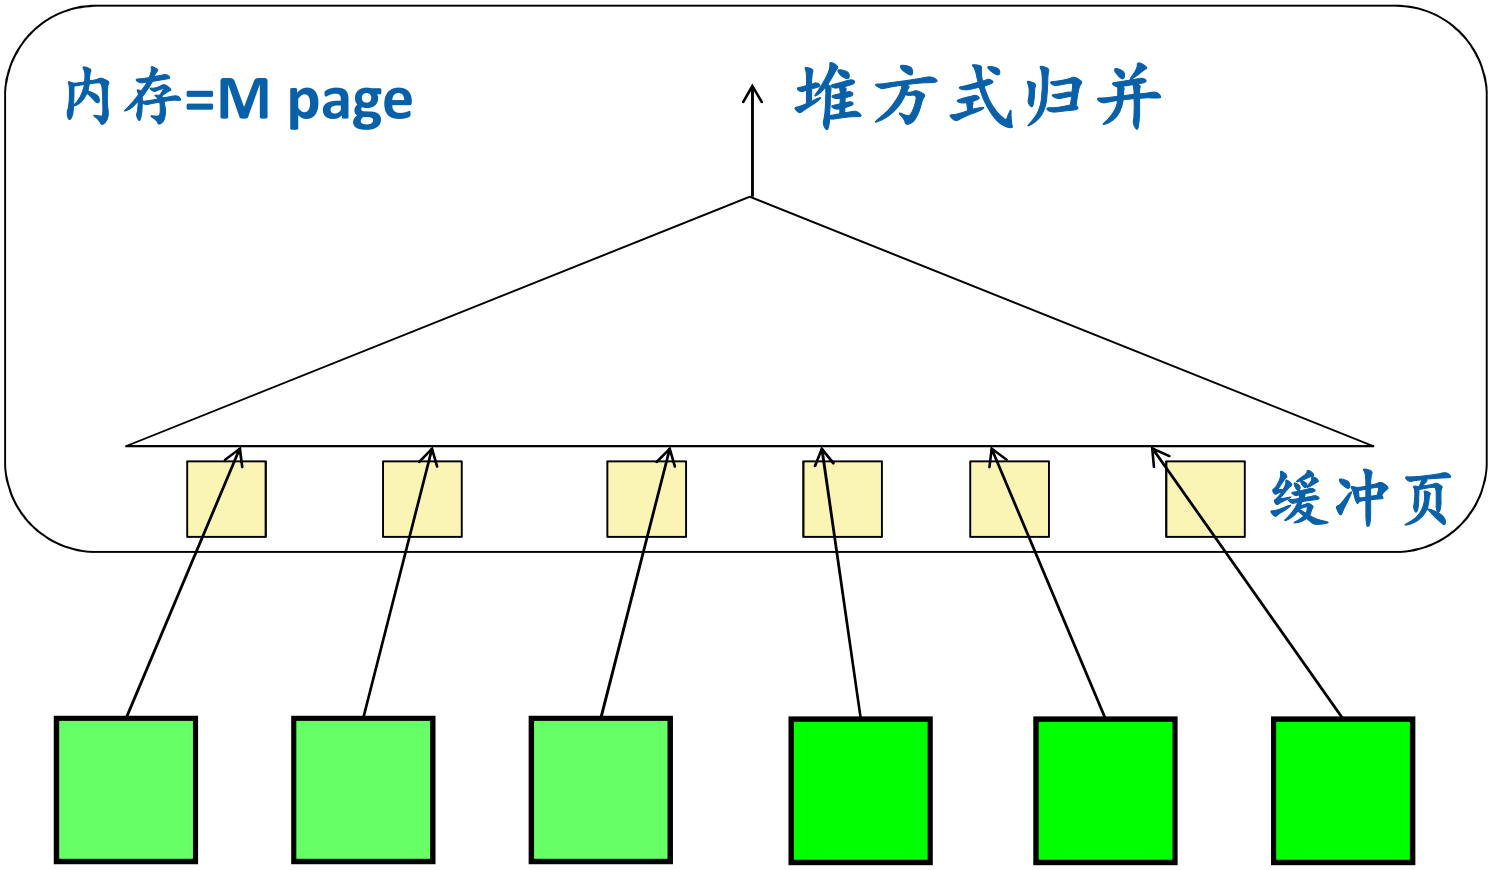

外存排序的I/O开销

- 假设一次Merge就可以完成

- I/O开销是多少？
  - 不考虑输出
  - Run generation: 读|R|页，写|R|页
  - Merge run: 读|R|页
  - 所以共读写3|R|页

单层Merge

- 可以最多把M-1个Run归并为1个Run
  - M-1个输入缓冲页
  - 1个输出缓冲页
  - 每次扫描全部内存记录，找到最小的输出

- 如果要求一定要用堆，那么需要考虑记录长度
  - 设可以支持X个输入，每个页可以放置L个记录
  - 那么堆有X-1个非叶子结点，需要(X-1)/L个页
  - 所以：X+(X-1)/L+1<=M
  - 可以求出X

多层Merge

- 如果数据超过了M-1个Run
  - (M-1)M个page
- 那么就需要多层Merge，需要的层数为
  - $log_{M-1}\frac{|R|}{M}$

Replacement Selection内存排序算法

- 目的：产生更长的Run
- 思路（从小到大排序）

```
读入数据占用所有内存;
找到最小的记录输出，last_key=输出记录的键;
while(1){
    当前内存有一个空位，所以可以读入一条新记录;
    在内存所有记录中找到>=last_key的最小键;
    if (没找到){
        当前Run结束；break;
    }
    输出相应的记录，last_key=输出记录的键;
}
```

Replacement Selection

- 优点
  - 可以证明：算法产生的Run的平均长度为2M
  - 所以，可以减少Run的数量
  - 有可能减少Merge层数
- 缺点
  - 内存排序算法效率低

考虑实际情况

- 假设计算机的可用内存为10GB
- 为了提高I/O效率，使用1MB大小的读写缓冲
  - 每次进行1MB的近似于顺序读写的操作
- 那么，内存单次Merge可以归并
  - 10GB/1MB – 1 ≈ 10^4
  - 那么单次Merge可以支持10^4*10GB=10^5GB=100TB
- 实际上，在大部分情况下，已经不需要Replacement Selection算法了

可以更快吗？

- 如果实际需要排序的数据比100TB小很多，那么在Merge阶段，Run的个数就少很多
- 于是，Merge阶段的内存就不需要完全占用
- 那么，我们可以利用这些多余的内存空间缓冲最后一个Run的部分数据，从而进一步减少I/O

Outline

- 查询处理概述
- 排序和外排序
  - 排序的应用场景
  - 内存排序回顾
  - 外存排序
  - 使用B^+-Tree获得排序数据

B+-Tree提供顺序

- B+-Tree的叶子结点给出了顺序
- 聚簇索引
  - 这个顺序也是表中记录的存储顺序
  - 可以直接访问，非常高效
- 二级索引
  - 这个顺序给出了RecordID
  - 通过RecordID访问Record需要随机I/O
  - 具体的代价需要考虑访问的数据量

二级索引访问举例

- 假设可用内存1GB
- 数据表有10GB大，每个记录100B
- 硬盘
  - 顺序访问速度：100MB/s
  - 随机访问速度：10ms/次
- 那么排序的时间
  - 3*10GB/100MB = 300 s
- 这相当于随机访问300s/10ms = 30000个记录的时间
- 换言之，当访问少于30000个记录时，采用二级索引是更快的，否则直接排序更快

小结

- 查询处理概述
  - 系统目录（System Catalog）
  - 查询执行方式
  - 关系操作实现的常见方式
- 排序和外排序
  - 排序的应用场景
  - 内存排序回顾
  - 外存排序
  - 使用B^+-Tree获得排序数据